
SY09 Projet : Student Alcohol Consumption

Ellen PILACHE, Thibault DELABY

Ce rapport présente les recherches du projet SY09

...



Table des matières

1	Introduction	2
2	Description et préparation des données	2
2.1	Structure et merge des données	2
3	Analyse Exploratoire	3
3.1	Description	3
3.2	Distribution des variables	3
3.3	Corrélation des variables	3
3.4	Analyse en Composantes Principales	4
4	Méthodes de classification non supervisée (Clustering)	4
4.1	K-Means	4
4.2	Classification Ascendante Hiérarchique	5
5	Méthodes de classification supervisée	5
5.1	Régression : K plus proches voisins (K-PPV) et régression logistique	5
5.1.1	Sélection de K par validation croisée (10 plis)	5
5.1.2	Analyse et accuracy	5
5.2	Analyse discriminante	6
6	Conclusion	6
	Références	7
	Annexe A Analyse exploratoire	8
	Annexe B ACP	9
	Annexe C Clustering	9
	Annexe D Méthodes supervisées	10



1 Introduction

Dans ce rapport, nous nous intéressons au jeu de données Student Alcohol Consumption, disponible sur la plateforme Kaggle. Ce jeu de données regroupe un ensemble de variables documentant le profil social, familial et scolaire d'élèves du secondaire, ainsi que leur niveau de consommation d'alcool en semaine et le week-end.

La consommation d'alcool chez les jeunes est un sujet de santé publique majeur, souvent lié à des facteurs environnementaux ou à des dynamiques de réussite et d'échec scolaire. Intuitivement, nous pouvons nous douter qu'il existe des relations complexes entre le cadre de vie d'un étudiant (statut familial, temps libre, vie sociale) et ses habitudes de consommation.

Dans ce rapport, nous souhaitons explorer et mettre en évidence ces interactions par différentes méthodes d'analyse de données (qu'elles soient descriptives, exploratoires ou prédictives) afin de dégager les facteurs d'influence majeurs. Ce rapport a donc pour but de répondre à la problématique générale suivante : *Dans quelle mesure les facteurs socio-éducatifs et familiaux influencent-ils la consommation d'alcool des étudiants, et quel est l'impact de cette consommation sur leur réussite scolaire ?*

Afin de répondre à cette problématique, nous structurons notre étude autour des questions suivantes :

- Quels liens structurels existent-ils entre le milieu de vie de l'étudiant (par exemple, la cohabitation avec les parents, la qualité des relations familiales) et l'intensité de sa consommation d'alcool le week-end ou en semaine ?
- Est-il possible de classer (ou typer) les profils de consommation des étudiants à partir de leurs variables de

comportement social (sorties, temps libre, consommation) ?

- Dans quelle mesure peut-on prédire l'ambition et la réussite scolaire d'un élève en combinant ses habitudes de consommation d'alcool et son assiduité (absences) ?

Ce document présentera tout d'abord une analyse descriptive et une préparation des données, avant d'exposer les différentes méthodes d'analyse de données retenues (analyses factorielles, classifications ou régressions) pour valider nos hypothèses. Nous concluons enfin en résumant les principaux résultats et en dégagant les perspectives de notre étude.

2 Description et préparation des données

2.1 Structure et merge des données

Les données proviennent de deux fichiers de la plateforme Kaggle correspondant aux enseignements de mathématiques (table mat, 395 élèves) et de portugais (table por, 649 élèves). Chaque table possède initialement 33 variables.

Pour centraliser les informations par étudiant, une jointure externe (outer join) a été effectuée sur un pivot d'identité de 27 variables communes (profil démographique, familial et habitudes de vie). Les caractéristiques propres à chaque cours (soutien payant paid, absences et notes trimestrielles G_1 , G_2 , G_3) ont été conservées de façon distinctes en appliquant les suffixes `_mat` et `_por`. Cela nous donne comme base de travail un tableau individu variable de dimension 674*38.



Pour certaines analyses, de nouvelles variables ont été définies, notamment la réussite en mathématiques, en portugais, ainsi qu'un indicateur de réussite globale binarisant les notes supérieures ou égales à 10. Toutes les variables ont été standardisées (centrées-réduites) pour éviter les biais liés à leur échelle.

3 Analyse Exploratoire

3.1 Description

Nous avons réalisé dans un premier temps une analyse descriptive afin d'obtenir des informations brutes classiques pour chaque variable du dataset mergé. Nous présentons ci-dessous les informations obtenues pour la consommation d'alcool en semaine (Dalc) et le weekend (Walc).

	Dalc	Walc
count	674.000000	674.000000
mean	1.500000	2.278932
std	0.920705	1.282851
min	1.000000	1.000000
25%	1.000000	1.000000
50%	1.000000	2.000000
75%	2.000000	3.000000
max	5.000000	5.000000

TABLE 1 – Statistiques descriptives pour Dalc et Walc

A première vue, on peut voir que la consommation d'alcool est assez faible en semaine et qu'elle augmente et se diversifie le weekend.

3.2 Distribution des variables

- *Distribution des absences* : Sur [figure 2](#) on remarque que les absences

suivent une distribution très asymétrique avec une forte concentration en zéro : la plupart des élèves sont assidus. On note que les absences ponctuelles sont plus fréquentes en portugais tandis que les absences élevées (>10) semblent proportionnellement plus importantes en mathématiques, suggérant un phénomène de décrochage plus marqué dans cette matière.

- *Niveau d'éducation des parents* (Medu/Fedu) : Selon [figure 4](#) Les mères présentent un niveau d'éducation légèrement supérieur à celui des pères dans l'échantillon.

- *Distribution des notes finales* (G3 maths vs portugais) Sur [figure 3](#), les deux distributions des notes finales sont approximativement unimodales et centrées, mais les notes de portugais sont en moyenne supérieures à celles de mathématiques.

3.3 Corrélation des variables

Nous avons regardé au niveau des corrélations entre les variables quantitatives ce qu'il en était :




FIGURE 1 – Matrice de corrélation sur 16 variables

À l'exception des notes du premier et du deuxième semestre, qui présentent une forte corrélation avec les résultats finaux, les variables étudiées semblent peu corrélées entre elles. Par conséquent, on ne s'attend pas à une grande efficacité des méthodes linéaires (ACP, Régression...).

3.4 Analyse en Composantes Principales

Pour l'Analyse en Composantes Principales (ACP), une première itération sur l'ensemble des données normalisées (figure 6) donne un premier axe expliquant 27,2 % de la variance et un deuxième axe à 10,1 %, soit un plan factoriel représentant seulement 37,3 % de la variance totale, ce qui reste assez limité pour une interprétation directe. Nous avons donc réalisé une seconde ACP ciblée (figure 7) sur quelques variables afin d'y voir plus clair. Nous avons sélectionné les variables familiales, de mode de vie et de consommation (Medu, Fedu, famrel, goout, freetime, Dalc, Walc, studytime, failures). Le cercle des corrélations (fi-

gure 8) révèle que goout et freetime sont fortement associés à la consommation d'alcool, tandis que studytime s'y oppose nettement. À l'inverse, le niveau d'éducation des parents (Medu, Fedu) apparaît peu corrélé aux autres variables dans ce plan. La projection des individus colorés par Walc confirme visuellement qu'une forte consommation le week-end est bien liée à davantage de sorties et de temps libre.

4 Méthodes de classification non supervisée (Clustering)

Dans une démarche de classification non supervisée, nous avons cherché à catégoriser les étudiants en profils comportementaux à partir des variables goout, freetime, Dalc et Walc, en appliquant deux méthodes : le K-Means et la Classification Ascendante Hiérarchique (CAH).

4.1 K-Means

La méthode du coude sur l'inertie intra-classe fait apparaître un coude pour $K = 2$, que nous retenons comme K_{opt} (figure 9). L'algorithme des K-Means (figure 10) distingue alors deux profils que nous avons déterminé en regardant le détail des variables utilisées (figure 11) :

- Les étudiants *festifs* : davantage de temps libre, sorties fréquentes et consommation d'alcool élevée.
- Les étudiants *studieux* : moins de temps libre, peu de sorties et consommation réduite.



4.2 Classification Ascendante Hiérarchique

La CAH avec le critère de Ward confirme la pertinence de deux clusters via le dendrogramme (figure 12). La comparaison des partitions K-Means et CAH, que nous avons visualisé dans le 1er plan factoriel (figure 13) et quantifiée par un indice de Rand ajusté (ARI) d'environ 0,6. Cela montre une concordance entre les deux méthodes, ce qui renforce la robustesse des profils identifiés.

pouvait être prédite à partir des autres variables.

5.1.1 Sélection de K par validation croisée (10 plis)

Comme illustré en figure 14, nous obtenons un K optimal égal à 8.

5.1.2 Analyse et accuracy

Nous obtenons une accuracy de 0,881 pour le K-PPV et de 0,852 pour la régression logistique quadratique, ce qui semble satisfaisant à première vue.

Cependant, en examinant la distribution de **higher** ainsi que la frontière de décision projetée sur deux axes (voir figure 16), on constate que 89 % des étudiants souhaitent poursuivre des études supérieures. Ainsi, un modèle renvoyant systématiquement la classe 1 atteindrait une accuracy supérieure à la nôtre, ce qui relativise fortement ce résultat.

La matrice de confusion correspondante est présentée en figure 15.

Nous avons réappliqué ces méthodes sur les variables *reussite_mat* et *reussite_por* dont les distributions sont plus équilibrées : 67 % de la classe 1 pour les mathématiques et 85 % pour le portugais.

Les valeurs de K sont respectivement 19 pour *reussite_mat* et 15 pour *reussite_por*. Nous trouvons des valeurs de précision à 0.658 pour les K-PPV et 0.620 pour la régression logistique.

La matrice de confusion associée est présentée en figure 17 et les frontières de décisions projetées en 2 dimensions en figure 18.

5 Méthodes de classification supervisée

Pour prédire si un étudiant souhaitait poursuivre des études supérieures ou son appartenance à la classe de réussite ($G3 \geq 10$, moyenne maths et portugais), nous avons mis en place deux algorithmes et les avons comparés par validation croisée à 10 plis (métrique : accuracy) : les K Plus Proches Voisins (K-PPV) et la Régression Logistique.

5.1 Régression : K plus proches voisins (K-PPV) et régression logistique

Nous avons appliqué des méthodes non linéaires susceptibles de donner de meilleurs résultats, dans la mesure où il existe très peu de corrélation linéaire entre les variables.

Dans un premier temps, nous avons cherché à déterminer si la volonté d'un étudiant de poursuivre des études supérieures (**higher**)



Cible	Modèle	P. cl. 0	P. cl. 1	Acc.
higher	KNN ($k = 8$)	0.50	0.90	0.889
	RL lin.	0.50	0.90	0.889
	RL quad.	0.33	0.92	0.852
reussite_mat	KNN ($k = 19$)	0.33	0.67	0.658
	RL quad.	0.38	0.68	0.620
reussite_por	KNN ($k = 15$)	0.00	0.85	0.846
	RL quad.	0.27	0.86	0.808

TABLE 2 – Précision par classe et accuracy globale KNN et RL quad.

Le [tableau 2](#) confirme ce déséquilibre : pour higher, la précision en classe 0 reste faible (0.33-0.50) malgré une accuracy élevée.

Req : Nous aurions pu utiliser d'autres métriques pour évaluer la performance des modèles comme le recall par exemple.

5.2 Analyse discriminante

L'analyse discriminante (linéaire ou quadratique) repose sur l'hypothèse que les variables explicatives suivent une loi normale multivariée au sein de chaque classe. Le test de Shapiro-Wilk appliqué à chacune des 21 variables numériques du jeu de données ($n=674$) rejette cette hypothèse pour toutes les variables ($p < 0.05$). En conséquence, les conditions d'application de l'analyse discriminante ne sont pas satisfaites.

6 Conclusion

Cette étude avait pour objectif d'explorer les relations entre les facteurs socio-éducatifs, la consommation d'alcool et la réussite scolaire d'élèves du secondaire à partir du jeu de données Student Alcohol Consumption.

L'analyse exploratoire a révélé de faibles corrélations linéaires entre les variables, ce qui a orienté nos choix vers des méthodes non linéaires. Les méthodes de clustering ont permis d'identifier deux profils comportementaux distincts, confirmés de manière cohérente par le K-Means et la CAH. Les

méthodes de classification supervisée se sont en revanche heurtées au déséquilibre des classes et à une séparabilité insuffisante des variables, limitant la portée des résultats obtenus.

Ces limites ouvrent la voie à des analyses complémentaires, notamment via l'enrichissement du jeu de données ou le recours à des métriques mieux adaptées aux classes déséquilibrées.



Références

- [1] CORTEZ, PAULO. *Student Alcohol Consumption*. Kaggle. 2016. URL : [https : / / www . kaggle . com / datasets/uciml/student-alcohol-consumption](https://www.kaggle.com/datasets/uciml/student-alcohol-consumption).
- [2] GOVAERT, GÉRARD AND DENEUX, THIERRY AND QUOST, BENJAMIN AND ROUSSEAU, SYLVAIN. *SY09 – Science des Données*. Polycopié de cours, UTC. 2025.



Annexe A Analyse exploratoire




FIGURE 2 – Distribution des absences en fonction des matières




FIGURE 4 – Distribution de l'éducation des parents




FIGURE 3 – Distribution des notes finales par matières




FIGURE 5 – Distribution de la consommation d'alcool en semaine et le week-end



Annexe B ACP

Annexe C Clustering




FIGURE 6 – ACP sur l'ensemble des données normalisées




FIGURE 9 – Règle du coude pour déterminer le nombre de clusters à utiliser




FIGURE 7 – ACP sur les variables ciblées




FIGURE 10 – Algorithme du K-Means utilisé sur les variables comportementales.




FIGURE 8 – Cercle des corrélations sur les variables ciblées




FIGURE 11 – Détail des moyennes pour les variables comportementales des deux clusters suite au K-Means




FIGURE 12 – Dendrogramme obtenu suite à la CAH




FIGURE 13 – Comparaison de clusterisation via le K-Means et la CAH

Annexe D Méthode supervi- sées




FIGURE 14 – Méthode du coude




FIGURE 15 – Matrices de confusion "higher"




FIGURE 16 – Frontière de décision "higher" sur school et famsize





FIGURE 17 – Matrice de confusion "reussite"




FIGURE 18 – Frontière de décision "reussite"